

FUTUREME AI · TECHNICAL & PRODUCT BRIEF

FutureMe AI Infrastructure

สรุปสำหรับทีม

ระบบไม่ได้ให้ AI ทายว่าเด็ก “ควรเป็นอะไร” แต่ช่วยเก็บหลักฐานจากตัวนักเรียน
เชื่อมหลักฐานนั้นกับข้อมูลอาชีพและหลักสูตรที่ตรวจสอบได้
แล้วเสนอหลายเส้นทางพร้อมเหตุผล ข้อจำกัด และแหล่งอ้างอิง

แกนของระบบ สนทนาและสร้าง Profile ☐ ค้นหาหลักฐานด้วย RAG ☐
ให้คะแนนแบบอธิบายได้ ☐ ตอบอย่างปลอดภัย

EXECUTIVE SUMMARY

สี่เรื่องที่ทุกคนในทีมต้องเข้าใจตรงกัน

FutureMe ไม่ใช่โมเดลก่อนเดียว แต่เป็นระบบหลายส่วนที่แบ่งหน้าที่กันชัดเจน

ถ้าส่วนใดส่วนหนึ่งรับผิดชอบมากเกินไป คำนะน่าจะตรวจสอบยากและเสี่ยงขึ้นได้

1. Base LLM เป็นตัวสนทนา ไม่ใช่ฐานข้อมูล

ใช้คุยกับนักเรียน สกัดข้อมูลเป็นโครงสร้าง
และเรียบเรียงคำอธิบาย แต่ไม่ควรใช้จำเกณฑ์รับสมัครหรือคิด
คะแนนความเหมาะสมเอง

2. RAG มีหน้าที่ค้นหลักฐาน

ค้นข้อมูลอาชีพ หลักสูตร เกณฑ์รับสมัคร
และแหล่งอ้างอิงที่เกี่ยวข้อง โดยกรองปี จังหวัด ระดับวุฒิ
และสถานะข้อมูลก่อน

3. Recommendation Engine เป็นคนให้คะแนน

คำนวณจากกติกาที่ทีมกำหนด แยกความสนใจ ทักษะ
บริบทงาน ข้อจำกัด และความพร้อมทางการศึกษา
เพื่อย้อนตรวจเหตุผลได้

4. LoRA เป็นงานหลัง validation


ใช้เมื่อมีตัวอย่างบทสนทนาคุณภาพสูงและพบว่า prompt
ยังไม่พอ ไม่ใช่สอนข้อเท็จจริงที่เปลี่ยนแปลงปี
และไม่ใช้ตัวกรองคำตอบขั้นสุดท้าย

ประโยคเดียวสำหรับเล่าให้คนอื่นฟัง: FutureMe คุยกับนักเรียนเพื่อสร้าง Learner Profile จากข้อมูลที่เด็กยืนยัน
เชื่อม Profile เข้ากับหลักสูตรและอาชีพผ่าน RAG แล้วเสนอหลายเส้นทางด้วยคะแนน เหตุผล
และหลักฐานที่ตรวจสอบได้

SYSTEM ARCHITECTURE

ภาพรวมระบบที่สั้นที่สุดและยังถูกต้อง

Student Intelligence Layer เป็นก้อนเดียวในมุมมองของผลิตภัณฑ์ ภายในมี LLM สำหรับสนทนา ตัวจัดการ Learner Profile และ RAG สำหรับค้นข้อมูล ส่วนการตัดสินใจเชิงคะแนนแยกออกมาเพื่อให้ตรวจสอบได้



วิธีอ่านภาพ: RAG ส่ง "หลักฐาน" ให้ Recommendation Engine ไม่ได้เป็นผู้เลือกเส้นทางแทนนักเรียน ส่วน LoRA เป็น adapter ทางเลือกหลังมี dataset ที่ดีแล้ว

COMPONENT RESPONSIBILITIES

แต่ละส่วนรับผิดชอบอะไร และส่งอะไรต่อ


การกำหนด input และ output ให้ชัดเจนตั้งแต่แรก ช่วยให้ทีมพัฒนาแยกกันได้ และลดปัญหาที่ LLM รับทุกหน้าที่จนทดสอบไม่ได้

1	Student / Web App	หน้าจอสนทนา แสดง Profile ให้เด็กตรวจสอบ แสดงหลายเส้นทาง เหตุผล แหล่งอ้างอิง และรับ feedback	ส่ง: ข้อความ การยืนยัน Profile ข้อจำกัด และ feedback
2	Student Intelligence Layer	คุยกับนักเรียน สร้างและอัปเดต Profile ตรวจสอบข้อมูลที่ยังขาด แล้วเรียก RAG เพื่อหาหลักฐาน	ส่ง: Profile + Constraints + Evidence + Confidence
3	Base LLM	เข้าใจภาษาธรรมชาติ ถ้ามอง สกัดบทสนทนาเป็น JSON และเรียบเรียงคำอธิบายจากข้อมูลที่เตรียมให้	ไม่ควรทำ: จำข้อมูลล่าสุด คิดคะแนน หรือพิมพ์ซ้ำ
4	Learner Profile DB	เก็บความสนใจ หลักฐานทักษะ บริบทงาน ข้อจำกัด เป้าหมาย confidence และสถานะการยืนยัน	ส่ง: Profile ที่มี version และเฉพาะ field ที่จำเป็น
5	Knowledge Base + RAG	เก็บข้อความเป็น claim/chunk พร้อม Vector และ metadata ค้นหาคำหมายและคำตรง แล้วกรองปี จังหวัด ระดับวุฒิ และสถานะ	ส่ง: Evidence ID, เนื้อหา, source, date และ retrieval score
6	Recommendation & Scoring	จับคู่ Profile กับเส้นทางที่พบ คำนวณคะแนนหลายมิติ ตรวจสอบเงื่อนไขบังคับ และสร้าง ranking	ส่ง: หลายเส้นทาง + score breakdown + reasons + gaps
7	Response & Safety	เรียบเรียงผล ตรวจสอบว่าข้อความสำคัญมีหลักฐาน ลดการพินิจและการตีตรา พร้อมยอมรับเมื่อข้อมูลไม่พอ	ส่ง: คำตอบหลายทางเลือกพร้อม citation
8	LoRA Adapter	ส่วนเสริมสำหรับปรับบทสนทนา การสกัด schema หรือการอธิบายตาม rubric เมื่อมีตัวอย่างคุณภาพสูง	MVP: ยังไม่จำเป็น เริ่มจาก prompt + evaluation ก่อน

TEXT □ VECTOR □ RETRIEVAL

ข้อมูลกลายเป็น Vector ได้อย่างไร

Vector Database ไม่ได้แปลงข้อความ ตัวที่ทำหน้าที่นั้นคือ Embedding Model ส่วน Vector Database มีหน้าที่เก็บ Vector และค้นคืนข้อความที่ความหมายใกล้กับคำถาม



ขั้นตอน	สิ่งที่ต้องทำ
1. เก็บต้นฉบับ	เก็บไฟล์แบบไม่แก้ไข พร้อม URL วันที่ดึง checksum และเงื่อนไขการใช้งาน
2. อ่านข้อความ	ใช้ parser ตามชนิดไฟล์ ถ้าเป็น PDF สแกนจึงค่อยใช้ OCR และตรวจลำดับการอ่าน
3. จัดโครงสร้าง	แยกชื่อหลักสูตร วิชาที่เรียน อาชีพปลายทาง ค่าใช้จ่าย และเกณฑ์สมัคร
4. แบ่ง Chunk	ใช้หัวข้อและความหมายเป็นหลัก ไม่ตัดกฏครึ่งประโยคหรือรวมหลายปีในก้อนเดียว
5. ตรวจแหล่ง	กำหนด verified, conditional หรือ unverified และไม่ index ข้อมูล unverified
6. สร้าง Embedding	ใช้ Embedding Model เดียวกันกับ chunk และคำค้น
7. เก็บ Vector	เก็บ Vector คู่กับข้อความ Evidence ID ปี จังหวัด ระดับวุฒิ และวันหมดอายุ
8. ทดสอบ Retrieval	ใช้คำถามไทยเหมือนภาษานักเรียนจริง แล้ววัด source recall และ citation precision

ค่าตั้งต้นสำหรับทดลอง

Chunk ราว 300-600 tokens และ overlap 50-100 tokens
กฎรับสมัครควรแบ่งตามหนึ่งเงื่อนไข ดึง candidate 15-20
ชิ้น แล้ว rerank เหลือ 5-8 ชิ้น

Metadata ที่ห้ามหาย

ชื่อเอกสาร ผู้เผยแพร่ URL เลขหน้า ปีการศึกษา รอบรับสมัคร
วันหมดอายุ ขอบเขต claim สถานะข้อมูล และผู้ตรวจ

RECOMMENDED MVP STACK

โปรแกรมที่แนะนำสำหรับเวอร์ชันแรก

ชุดนี้เน้นทำเดโมได้เร็ว แต่ยังต่อยอดเป็น production ได้ โปรแกรมเปลี่ยนภายหลังได้
ตารางใดที่สัญญาข้อมูลระหว่างแต่ละส่วนยังเหมือนเดิม

ส่วน	ตัวเลือก	หน้าที่	สถานะ
Frontend	Next.js	หน้าแชต Profile editor ผลลัพธ์ และแหล่งอ้างอิง	ทำตอนนี้
Backend API	Python + FastAPI	ควบคุม session, profile, RAG, scoring และ model call	ทำตอนนี้
Document parsing	Unstructured + PyMuPDF	อ่านข้อความจาก PDF, Word, HTML และ OCR เมื่อจำเป็น	ทำตอนนี้
RAG orchestration	LlamaIndex หรือ Python ตรง ๆ	จัด ingestion, chunking, retrieval และ context	เลือกหนึ่งทาง
Embedding	BGE-M3 + Sentence Transformers	แปลงข้อความไทย/อังกฤษเป็น Vector	ทดลองก่อน
Vector Database	Qdrant	เก็บ Dense/Sparse Vector, payload และ hybrid search	ทำตอนนี้
Relational DB	PostgreSQL	เก็บ Profile ข้อมูลโครงสร้าง กฎ และคะแนน	ทำตอนนี้
Raw file storage	S3-compatible / MinIO	เก็บต้นฉบับแบบ immutable พร้อม checksum	ทำตอนนี้
Base LLM	Model API + structured output	สนทนา สกัด Profile และอธิบายจาก evidence	ใช้ API ก่อน
Deployment	Docker Compose	รันในเครื่องก่อนย้ายขึ้น managed containers	เริ่มง่ายก่อน
LoRA / Graph	เพิ่มหลัง baseline	แก้เฉพาะปัญหาที่พิสูจน์แล้ว	ทำภายหลัง

ถ้าต้องการลดจำนวนระบบในเดโม: ใช้ PostgreSQL + pgvector แทน Qdrant ได้ แต่หากต้องการ Dense + Sparse + Hybrid Search ตั้งแต่แรก Qdrant จะจัดการ retrieval ได้ตรงกว่า

DATA PLACEMENT

อะไรควรเก็บเป็น Vector และอะไรไม่ควร

ข้อมูลที่ต้องคัดจากความหมายเหมาะกับ Vector Database ส่วนข้อมูลที่ต้องกรอง เปรียบเทียบ คำนวณ หรือควบคุม version เหมาะกับฐานข้อมูลเชิงโครงสร้าง

ข้อมูล	ตำแหน่ง	เหตุผล	Metadata
คำอธิบายอาชีพ	Vector DB	คัดจากภาษาของนักเรียนที่ไม่ตรงกับชื่อทางการ	occupation_id, source
คำอธิบายหลักสูตร	Vector DB	คัดจากความสนใจและทักษะ	program_id, level, province
เกณฑ์รับสมัคร	Vector + PostgreSQL	คัดข้อความ แต่ตรวจเงื่อนไขและปีด้วย field	cycle, valid_until, status
ค่าเทอม / คະแนน / จังหวัด	PostgreSQL	กรองและเปรียบเทียบค่าที่แน่นอน	year, unit, currency
Learner Profile / consent	PostgreSQL แยกสิทธิ์	แก้ ลบ ทำ version และควบคุมสิทธิ์	confirmed_at, retention
PDF ดัชนีฉบับ	Object Storage	หลักฐานต้นทางแบบ immutable	checksum, retrieved_at

ตอนนักเรียนคุยหนึ่งรอบ ข้อมูลไหลอย่างไร

รอบ	ขั้น	สิ่งที่เกิดขึ้น
1	รับข้อความ	รับข้อความและ session โดยไม่ส่ง identity เกินจำเป็น
2	สกัด Profile	LLM คัด structured output และข้อมูลที่ยังขาด
3	ให้เด็กยืนยัน	ข้อมูลดีความต้องการแก้ไขได้ก่อนใช้
4	สร้างคำค้น	เลือก index และ metadata filter จาก Profile
5	คัด Evidence	RAG คัด source, date, status และ score
6	คำนวณคะแนน	Scoring ให้คะแนนและตรวจเงื่อนไขบังคับ
7	เรียบเรียง	LLM รับ Profile ที่จำเป็น ผลคะแนน และ evidence
8	ตรวจและเรียนรู้	Safety ตรวจ citation แล้ว feedback ย้อนเข้า Profile

EXPLAINABLE RECOMMENDATION

คะแนนต้องบอกได้ว่าเกิดจากอะไร

ตัวเลขด้านล่างเป็นตัวอย่างสำหรับเริ่มออกแบบ ไม่ใช่คำแนะนำที่ล็อกแล้ว ก่อนใช้จริงต้องทดสอบกับ counselor และนักเรียนหลายกลุ่ม

มิติ	ตัวอย่างน้ำหนัก	หลักฐานที่ใช้
Interest fit	30%	ความสนใจที่เด็กยืนยันและเหตุการณ์ตัวอย่าง
Evidence-backed skill fit	25%	ทักษะที่มีผลงานหรือหลักฐานรองรับ
Constraint feasibility	20%	งบประมาณ พื้นที่ เวลา สุขภาพ และภาษา
Work-context fit	15%	ลักษณะงานและสภาพแวดล้อมที่ขอบ
Education readiness	10%	พื้นฐานวิชา คุณสมบัติ และเกณฑ์รับสมัคร

คะแนนไม่ใช่ค่าตัดสิน: ควรเขียนว่า “จากข้อมูลที่ให้มา เส้นทางนี้ควรทดลองสำรวจต่อ” ไม่ใช่ “AI รู้ว่าคุณเหมาะกับอาชีพนี้” และต้องแสดงทั้ง reasons, gaps และ evidence IDs

เพราะผู้ใช้เป็นนักเรียน ความปลอดภัยต้องอยู่ในโครงสร้าง

Data minimization

เก็บเฉพาะข้อมูลจำเป็นต่อการแนะนำ

Identity separation

แยก identity ออกจาก Learner Profile

Consent & control

มี export แก้ไข และลบข้อมูล

No implicit training

ไม่นำบทสนทนาไปฝึกโดยอัตโนมัติ

Evidence-first

ข้อเสนอสำคัญต้องมีหลักฐาน

Human review

เปิดทางให้ครูหรือผู้เชี่ยวชาญทบทวน

MVP BUILD ORDER

ลำดับสร้างที่ช่วยลดความเสี่ยง

อย่าเริ่มจาก LoRA หรือโมเดลใหญ่ที่สุด ให้เริ่มจากข้อมูลที่ตรวจสอบได้ แล้วค่อยพิสูจน์ว่า retrieval และ recommendation มีประโยชน์จริง

PHASE 1	Data foundation	ล็อก schema และสร้าง source registry กับ quarantine	ผ่านเมื่อทุก edge มี source, status และวันที่ตรวจ
PHASE 2	Guided discovery	ทำบทสนทนาและ Profile แบบ structured ที่เด็กแก้ไขได้	ผ่านเมื่อแยกสิ่งที่รู้กับสิ่งที่คาดได้
PHASE 3	RAG + scoring	index ข้อมูล verified ให้คะแนนหำมิดี และส่งหลายเส้นทาง	ผ่านเมื่อคำแนะนำโยงถึง Profile และ evidence ได้
PHASE 4	Evaluation & trial	ทดสอบ retrieval, mapping, safety และ usefulness หลายบริบท	ผ่านเมื่อเด็กเข้าใจเหตุผลและรู้ก้าวทดลองต่อ
PHASE 5	Optimization	เพิ่ม reranker, LoRA, graph หรือ autoscaling จากปัญหาที่วัดได้	ผ่านเมื่อ metric ดีขึ้นเหนือ baseline

หกอย่างที่ทีมควรหลีกเลี่ยงตั้งแต่ต้น

- ใส่ทุกอย่างลง Vector DB จนรอกค่าเทอม ปี และเงื่อนไขไม่ได้
 - รวมหลายหัวข้อหรือหลายปีไว้ใน Chunk เดียว
 - นำข้อมูล unverified หรือหมดอายุเข้า production
- ปล่อยให้ LLM คิดคะแนนหรือสร้างเหตุผลที่ไม่มีใน evidence
 - ใช้ LoRA จำหลักสูตรและเกณฑ์ที่เปลี่ยนทุกปี
 - ให้ผลลัพธ์เป็นคำตอบเดียวจนดูเหมือน AI ตัดสินชีวิตแทน

ระบบที่ดีไม่ได้ตอบเร็วที่สุด แต่ช่วยให้เด็กตัดสินใจจากข้อมูลที่เห็นและโต้แย้งได้

เป้าหมายของ MVP จึงไม่ใช่ทำให้ AI ดูฉลาดที่สุด แต่คือพิสูจน์ว่า Profile ถูกสร้างอย่างไม่น่า RAG ค้นหลักฐานได้ตรง คะแนนอธิบายได้ และเด็กมองเห็นก้าวทดลองถัดไปของตัวเอง

Build evidence first. Optimize the model later.

REFERENCES

เอกสารอ้างอิงสำหรับทีม

- 1 FutureMe AI - RAG Data Specification. เอกสารภายในโปรเจกต์ **Data/RAG_DATA_SPEC.md**
- 2 FutureMe AI - AIS Cloud Architecture and Deployment. เอกสารภายในโปรเจกต์ **Data/06_AIS_Cloud_and_Infrastructure/01_AIS_Cloud_Architecture_and_Deployment.md**
- 3 Unstructured - Document Partitioning สำหรับการอ่านเอกสารและ OCR
- 4 BAAI - BGE-M3 Model Card สำหรับ Embedding แบบ multilingual
- 5 Qdrant - Hybrid Search สำหรับ Dense + Sparse retrieval
- 6 pgvector ทางเลือกสำหรับค้น Vector ใน PostgreSQL

เอกสารนี้เป็น design brief โปรแกรมและค่านำหนักเป็นจุดเริ่มต้นสำหรับ MVP ทีมต้องยืนยันด้วย retrieval evaluation, counselor review, student testing และข้อกำหนดข้อมูลของบริการที่เลือกก่อนขึ้น production